

CLIP

CLIP

Learning Transferable Visual Models From Natural Language Supervision

1 Introduction

기존 문제

일반적인 이미지 분류 모델은 보통 다음처럼 학습함

| 이미지 → 사전에 정해진 클래스 중 하나 예측

ex

- 고양이
- 강아지
- 자동차
- 비행기

ImageNet 모델이라면 **ImageNet에 정의된 1000개 클래스**를 맞히도록 학습됨

문제는 새로운 개념을 추가하려면 새로운 라벨 데이터가 필요하다는 것

예를 들어 기존 모델이

| 고양이 / 강아지 / 자동차

만 학습했다면 갑자기

| 드론을 분류해줘

라고 했을 때 바로 대응하기 어렵고 새로운 데이터셋을 수집하고 라벨링한 뒤 다시 학습하거나 fine-tuning해야 함

기존 방식

이미지 → 고정된 클래스 분류기

CLIP

이미지 ↔ 자연어 설명을 연결

이 차이가 핵심임

CLIP은 인터넷에서 쉽게 얻을 수 있는 이미지와 자연어의 관계 자체를 supervision으로 사
용함

그래서 사람이

| 이 이미지는 class 342입니다

처럼 정형화된 라벨을 붙이지 않아도

| a dog playing in the park
a red sports car
a bowl of ramen

같은 자연어를 이용해 시각적 개념을 학습할 수 있음

논문에서는 인터넷에서 수집한 **4억 개의 이미지-텍스트 쌍**을 이용해 CLIP을 학습했고, 30
개가 넘는 비전 데이터셋에서 별도의 task-specific 학습 없이 zero-shot 성능을 평가함

CLIP

Contrastive Language-Image Pre-training

핵심 아이디어: 어떤 이미지와 어떤 문장이 서로 짝인지 맞히도록 학습

예를 들어 학습 배치에 다음 데이터가 있다고 가정

- 🐶 사진 ↔ "a photo of a dog"
- 🚗 사진 ↔ "a red car"
- 🍕 사진 ↔ "a pizza"

CLIP은

- 강아지 사진 ↔ "a photo of a dog" → 가까워지도록
- 강아지 사진 ↔ "a red car" → 멀어지도록
- 강아지 사진 ↔ "a pizza" → 멀어지도록

학습함

즉 이미지와 텍스트를 같은 임베딩 공간에 넣고 의미가 맞으면 가까이, 틀리면 멀리 배치하는
방식

CLIP의 핵심

1. Natural Language Supervision

사람이 만든 고정 클래스 대신 자연어를 supervision으로 사용

2. Contrastive Learning

이미지에 대한 정확한 문장을 맞히고 틀린 문장은 구별하도록 학습

3. Large-scale Pre-training

4억 개의 이미지-텍스트 쌍으로 학습

4. Zero-shot Transfer

새로운 데이터셋의 학습 이미지를 보여주지 않고 클래스 이름만 자연어로 주어 분류 가능

5. 범용적인 이미지 표현

객체뿐 아니라 행동, 장소, 글자, 음식, 장면 등 다양한 시각적 개념 학습

2 Approach

CLIP 구조

1. 학습

Image Encoder + Text Encoder → 같은 임베딩 공간에서 이미지와 텍스트를 맞춤

2. 추론

클래스 이름을 문장으로 변환 → Text Encoder → 이미지와 가장 비슷한 문장 선택

CLIP에는 일반적인 이미지 분류 모델처럼 처음부터 고정된 1000-class Linear Classifier가 존재하는 것이 아니라 텍스트를 이용해 그때그때 분류기를 만들어냄

⇒ CLIP의 zero-shot transfer가 가능한 가장 중요한 이유

2.1 Natural Language Supervision

CLIP의 가장 중요한 출발점은 자연어 자체를 시각 모델의 학습 신호로 사용하자라는 아이디어

기존 supervised learning은 이미지 → 정답 라벨 형태

예를 들어

| 🐶 → dog

하지만 인터넷에는 이런 깔끔한 라벨보다

| 🐶 → "Pepper the aussie pup"

처럼 이미지와 관련된 자연어가 훨씬 많음

CLIP은 이 자연어를 그대로 활용함

왜 자연어가 좋은가

1. 사람이 별도로 라벨링하지 않아도 됨

인터넷에는 이미지와 제목, 설명, 캡션 등이 이미 함께 존재

→ 새로운 라벨 데이터셋을 직접 만드는 비용 감소

2. 표현 가능한 개념의 범위가 훨씬 넓음

ImageNet의 클래스처럼 고정된 명사뿐 아니라

- running
- smiling
- rainy weather
- a satellite photo
- handwritten text
- a person playing basketball

등 다양한 개념 표현 가능

3. Zero-shot transfer 가능

언어와 이미지가 연결되어 있기 때문에

| "a photo of a zebra"

라는 텍스트를 입력하면 모델이 학습 중 직접 **zebra**라는 고정 클래스를 분류하도록 훈련되지 않았더라도 관련 시각 특징을 활용할 가능성이 생김

즉 CLIP은 단순히 좋은 이미지 **feature**만 배우는 것을 넘어

| 시각적 개념 ↔ 언어

사이의 연결 관계를 학습하는 모델임

2.2 Creating a Sufficiently Large Dataset

자연어 supervision을 쓰려면 대량의 **이미지-텍스트 쌍**이 필요함

기존 데이터셋에는 한계가 있었음

- MS-COCO → 약 10만 장 수준
- Visual Genome → 약 10만 장 수준
- YFCC100M → 규모는 크지만 자연어 metadata 품질이 일정하지 않음

특히 YFCC100M을 영어 자연어 제목이나 설명이 있는 이미지로 필터링하면 약 **1500만 장 수준**까지 줄어듦

그래서 연구진은 새로운 데이터셋을 구성함

WIT

WebImageText

규모

| 약 4억 개의 image-text pairs

인터넷의 공개된 여러 소스에서 이미지와 관련 텍스트를 수집함

다양한 개념을 최대한 포함시키기 위해 약 **50만 개의 검색 query**를 만들고, 특정 query가 데이터셋을 지나치게 지배하지 않도록 query 하나당 최대 약 2만 개의 이미지-텍스트 쌍을 사용함

최종적으로 약 4억 개의 이미지-텍스트 쌍으로 구성된 데이터셋을 만들었으며 연구진은 이를 **WIT, WebImageText**라고 부름

중요한 차이

ImageNet은 대략

| 이미지 → 사람이 정한 category

WIT은

| 이미지 ↔ 인터넷에 존재하는 자연어

형태

따라서 데이터는 훨씬 크고 다양한 대신 **noise도 많음**

즉 정확하게 정제된 작은 데이터보다

┃ 거대한 규모의 느슨한 자연어 supervision

을 선택한 것

2.3 Selecting an Efficient Pre-Training Method

처음부터 Contrastive Learning을 사용한 것은 아님

연구진은 먼저

┃ 이미지 → 해당 이미지의 caption 생성

방식을 실험함

즉 Image Encoder가 이미지를 보고 Text Transformer가 문장을 생성하는 방식

하지만 문제가 있었음

Caption Prediction의 문제

사진 한 장에 대해 가능한 문장은 매우 많음

예를 들어 같은 강아지 사진이라도

- a dog
- a cute puppy
- a dog playing outside
- my puppy Pepper
- an Australian shepherd

모두 맞는 설명임

그런데 생성 모델은 **정확히 어떤 단어들이 나오는지**까지 예측해야 함

→ 시각적 의미를 배우는 것보다 훨씬 어려운 문제

실제로 논문에서 Transformer 기반 caption prediction은 더 단순한 Bag-of-Words prediction보다 ImageNet zero-shot 학습 효율이 약 3배 낮았음

그래서 문제 자체를 바꿈

┃ 문장을 생성하지 말고 이 사진과 이 문장이 서로 짝인지 맞히자

이것이 CLIP의 Contrastive Learning임

Contrastive objective로 변경했을 때 Bag-of-Words prediction보다 다시 약 **4배 효율** 향상을 확인함

Contrastive Learning

배치 안에 이미지-텍스트 pair가 NN개 있다고 가정

$(I_1, T_1), (I_2, T_2), \dots, (I_N, T_N)$

각 이미지와 모든 텍스트를 비교함

	T ₁	T ₂	T ₃
I ₁	✓	✗	✗
I ₂	✗	✓	✗
I ₃	✗	✗	✓

대각선

$(I_1, T_1), (I_2, T_2), (I_3, T_3)$ 은 실제 pair → **Positive**

나머지는 $(I_1, T_2), (I_1, T_3), \dots$ → **Negative**

CLIP의 목표

- Positive similarity ↑
- Negative similarity ↓

전체 흐름

이미지 인코더

$$I_f = f_\theta(I)$$

텍스트 인코더

$$T_f = g_\phi(T)$$

각 feature를 joint embedding space로 projection

$$I_e = \frac{I_f W_i}{\|I_f W_i\|}$$

$$T_e = \frac{T_f W_t}{\|T_f W_t\|}$$

즉 이미지와 텍스트를 같은 차원의 벡터로 만들고 **L2 normalization**함

이제 similarity 계산

$$s_{ij} = I_{e_i}^T T_{e_j}$$

두 벡터가 정규화되어 있기 때문에 이 내적은 사실상 **cosine similarity**

- 값이 큼 → 의미적으로 비슷
- 값이 작음 → 의미적으로 다름

여기에 학습 가능한 temperature를 적용

$$\text{logit}_{ij} = \exp(t) \cdot I_{e_i}^T T_{e_j}$$

그리고 두 방향으로 classification 수행

Image → Text

이미지 I_i 를 보고 N개의 텍스트 중 진짜 짝 T_i 가 무엇인가를 맞힘

Text → Image

텍스트 T_i 를 보고 N개의 이미지 중 진짜 짝 I_i 가 무엇인가를 맞힘

$$\text{최종 loss } L = \frac{L_{\text{image} \rightarrow \text{text}} + L_{\text{text} \rightarrow \text{image}}}{2}$$

두 loss 모두 Cross Entropy 사용

논문의 핵심 구현도 이미지와 텍스트를 각각 인코딩하고 정규화한 뒤 $N \times N \times N$ cosine similarity matrix를 만든 다음 양방향 Cross Entropy를 평균하는 구조임

왜 양방향으로 학습할까

강아지 사진이 주어졌을 때

| 어떤 문장이 이 사진인가

만 배우는 것이 아니라

"a dog"라는 문장이 주어졌을 때

| 어떤 이미지가 이 문장인가

도 동시에 배우는 것

그래서 **Image ↔ Text**가 서로 같은 공간에 정렬됨

CLIP이 실제로 배우는 것

중요한 점은 CLIP이

| 사진에 어떤 픽셀들이 있는지 그대로 기억하는 것

이 목적이 아니라는 것

예를 들어 여러 데이터에서

- 강아지 사진 ↔ "dog"
- 강아지 사진 ↔ "puppy"
- 강아지 사진 ↔ "a pet"
- 자동차 사진 ↔ "car"

관계를 반복해서 보게 됨

그러면서 dog라는 언어 개념과 강아지의 시각적 특징이 연결됨

즉 언어를 기준으로 시각적 의미 공간을 만드는 것

2.4 Choosing and Scaling a Model

CLIP은 하나의 특정 Image Encoder만 사용하는 모델이 아님

논문에서는 크게 두 종류를 실험함

Image Encoder

ResNet

기본은 ResNet-50

하지만 일반 ResNet과 완전히 동일하지는 않음

- ResNet-D 계열 개선 적용
- anti-aliased blur pooling 적용
- 마지막 global average pooling을 **attention pooling**으로 교체

즉 이미지 전체를 그냥 평균내는 대신 attention을 이용하여 중요한 정보를 모으도록 변경함

Vision Transformer

ViT도 사용

이미지를 여러 patch로 나눈 뒤 Transformer를 이용해 처리함

실험 결과 규모가 커질수록 ViT 기반 CLIP이 높은 계산 효율을 보였음

Text Encoder

Text Encoder는 **Transformer**

기본 모델

- 12 layers
- width 512
- 8 attention heads
- 약 63M parameters
- vocabulary 49,152
- BPE tokenizer 사용


텍스트 구조

[SOS], token1, token2,...,[EOS]

마지막 Transformer layer에서 **[EOS] token의 representation**을 문장 전체의 feature로 사용함

그 후 LayerNorm → Linear Projection을 거쳐 이미지와 동일한 multimodal embedding space로 이동시킴

전체 구조



여기서 중요한 부분은 **이미지와 텍스트 사이에 복잡한 Cross-Attention이 존재하지 않는다는 점**

각각 독립적으로 인코딩한 뒤 **마지막 embedding의 dot product만 계산**

그래서 대규모 이미지 검색 같은 작업에서도 효율적임

2.5 Training

논문에서는 총 **8개 모델**을 학습

ResNet

- RN50
- RN101
- RN50×4
- RN50×16
- RN50×64

Vision Transformer

- ViT-B/32
- ViT-B/16
- ViT-L/14

모든 모델을 기본적으로 **32 epochs** 학습

Optimizer

| Adam 계열 + weight decay

Learning Rate

| cosine schedule

Batch size

| **32,768**

상당히 큰 batch를 사용함

Contrastive Learning에서는 batch 안의 다른 데이터들이 negative가 되기 때문에 batch가 크면 한 번에 많은 negative pair를 확보할 수 있음

예를 들어 batch에 32,768개의 image-text pair가 있으면

$32,768 \times 32,768$

크기의 similarity matrix를 계산함

그중 정답 pair는 32,768개이고 나머지는 negative 관계

가장 큰 모델

RN50×64

- 592개의 V100 GPU
- 약 18일

ViT-L/14

- 256개의 V100 GPU
- 약 12일

최종적으로 ViT-L/14를 **336px 해상도로 한 epoch 추가 학습한 ViT-L/14@336px**가 논문에서 가장 좋은 CLIP 모델로 사용됨

3 Experiments

CLIP의 실험은 단순히

| ImageNet 정확도가 높은가

만 확인하는 것이 아님

연구진이 보고 싶은 핵심은 **한 번 대규모로 학습한 모델이 새로운 데이터셋과 새로운 task에 얼마나 잘 전이되는가**

였음

그래서 30개가 넘는 데이터셋을 활용해 다양한 방식으로 평가함

3.1 Zero-Shot Transfer

3.1.1 Motivation

보통 컴퓨터 비전의 zero-shot learning은

| 학습하지 않은 새로운 class를 맞추는 것

을 의미함

하지만 CLIP 논문에서는 이를 더 넓게 해석함

| **학습하지 않은 새로운 데이터셋과 task에 바로 적용**

즉 단순히 새로운 종류의 동물을 맞추는 것이 아니라

- 물체 분류
- 음식 분류
- 행동 인식
- OCR
- 장소 인식
- 위성 영상 분류

등 서로 다른 task까지 적용해봄

연구진은 이를 CLIP이 단순히 좋은 representation을 학습했는지뿐 아니라 **task 자체를 얼마나 학습했는지 확인하는 방법**으로 봄

3.1.2 Using CLIP for Zero-Shot Transfer

여기가 CLIP에서 가장 중요한 부분 중 하나

예를 들어 데이터셋 클래스가

- plane
- car
- dog
- bird

라고 가정

먼저 클래스 이름을 자연어 prompt로 만들

```
"A photo of a plane"
"A photo of a car"
"A photo of a dog"
"A photo of a bird"
```

각 문장을 Text Encoder에 넣음

T_{plane} , T_{car} , T_{dog} , T_{bird}

그러면 이 벡터들이 사실상 **classifier의 weight 역할**을 하게 됨

새 이미지가 들어오면 $I = \text{ImageEncoder}(\text{image})$

그리고 각각과 cosine similarity 계산

$\text{sim}(I, T_{plane})$

$\text{sim}(I, T_{\text{car}})$

$\text{sim}(I, T_{\text{dog}})$

$\text{sim}(I, T_{\text{bird}})$

가장 similarity가 높은 클래스 선택

예를 들어

```
plane = 0.11
car    = 0.08
dog    = 0.82
bird   = 0.21
```

이면

| dog

로 예측

핵심

기존 모델 학습할 때 classifier weight를 학습

CLIP: 텍스트를 입력해서 **classifier weight**를 만들어냄

그래서 새로운 클래스를 추가해도 모델을 다시 학습할 필요가 없음

```
"a photo of a tiger"
"a photo of a drone"
"a photo of a hamburger"
```

처럼 Text Encoder에 새로운 문장만 넣으면 됨

이것이 CLIP의 **zero-shot classifier**임

3.1.3 Initial Comparison to Visual N-Grams

이전에도 자연어를 이용해 zero-shot image classification을 시도한 Visual N-Grams 라는 연구가 있었음

대표 결과

Dataset	Visual N-Grams	CLIP
aYahoo	72.4	98.4

Dataset	Visual N-Grams	CLIP
ImageNet	11.5	76.2
SUN	23.0	58.5

CLIP이 크게 높은 결과를 보임

다만 논문에서도 강조하듯 이것을 **완전히 공정한 동일 조건 비교로 해석하면 안 됨**

CLIP은

- 훨씬 큰 데이터
- 훨씬 많은 training compute
- 더 발전된 architecture

를 사용했기 때문임

3.1.4 Prompt Engineering and Ensembling

CLIP에서 굉장히 중요한 발견

클래스 이름만 입력하는 것보다 자연스러운 문장으로 만들어주는 것이 성능이 좋아짐

예를 들어

dog

보다

A photo of a dog

가 더 좋음

왜냐하면 CLIP이 학습할 때 이미지와 함께 등장한 텍스트는 단순한 단어 하나보다 **문장 형태인 경우가 많았기 때문**

⇒ 학습 데이터의 텍스트 형태와 inference 때의 텍스트 형태를 비슷하게 맞춰주는 것

Polysemy 문제

단어 하나만 넣으면 의미가 모호할 수도 있음

예를 들어 boxer는

- 복서라는 직업

- Boxer라는 강아지 품종

둘 다 가능

따라서 Oxford-IIIT Pets에서는

```
A photo of a boxer, a type of pet
```

처럼 context를 추가

Food101에서는

```
| a type of food
```

항공기 분류에서는

```
| a type of aircraft
```

위성 이미지에서는

```
a satellite photo of a {label}
```

처럼 task에 맞게 prompt 변경

Prompt Ensembling

한 prompt만 사용하지 않고 여러 표현을 사용함

예를 들어

```
A photo of a dog  
A photo of a small dog  
A photo of a large dog  
A blurry photo of a dog
```

각각 text embedding을 생성한 뒤 embedding을 결합

ImageNet에서는 **80개의 prompt template**을 ensemble했고 단일 기본 prompt보다 약 3.5%의 추가 향상을 보였으며, 클래스 이름만 사용하는 방식과 비교하면 prompt engineering + ensembling으로 거의 5%의 향상을 얻음

이 결과가 중요한 이유

CLIP에서 prompt는 단순히 보기 좋은 문장이 아니라

| 모델이 어떤 task를 수행해야 하는지를 정의하는 인터페이스

역할을 함

그래서 이후 Vision-Language Model 연구에서 **Prompt Engineering**이 중요해지는 출발점 중 하나가 됨

3.1.5 Analysis of Zero-Shot CLIP Performance

CLIP의 zero-shot 성능을 여러 데이터셋에서 평가

잘하는 분야

- 일반 객체 분류
- 음식
- 반려동물
- 장면
- 행동 인식
- 일부 OCR
- 일부 장소 인식

27개 데이터셋에서 zero-shot CLIP과 ResNet-50 feature에 supervised logistic regression을 학습한 baseline을 비교했을 때 **16개 데이터셋에서 zero-shot CLIP이 더 높은 결과를 기록함**

약한 분야

반대로 CLIP이 매우 약한 task도 존재

- EuroSAT → 위성 영상
- PatchCamelyon → 의료 영상
- CLEVRCounts → 물체 개수 세기
- GTSRB → 독일 교통표지판
- KITTI Distance → 자동차 거리 추정

특히 **counting**처럼 추상적이고 체계적인 **reasoning**이 필요한 task에서는 약함 따라서

| CLIP이 모든 새로운 문제를 해결한다

는 의미의 zero-shot 모델은 아님

Zero-shot vs Few-shot

흥미로운 결과가 있음

CLIP zero-shot은 같은 CLIP feature에서 학습한 **평균적인 4-shot logistic regression**과 **비슷한 성능**을 보임

ImageNet에서는 같은 CLIP feature의 약 **16-shot classifier** 수준과 비슷함
논문의 해석은 자연어에는 이미

| 우리가 어떤 개념을 원하는가

라는 강력한 사전 정보가 들어 있다는 것

이미지 한 장만 보여주면서

| 이것이 새로운 클래스야

라고 하는 것보다

| "a photo of a dog"

처럼 언어로 개념 자체를 설명하는 것이 경우에 따라 더 많은 정보를 제공할 수 있음

Scale

모델 규모와 계산량을 증가시키면 CLIP의 평균 zero-shot error가 꾸준히 감소하는 경향을 확인

즉 GPT 계열에서 관찰된 것처럼 CLIP에서도 어느 정도

| **Scale ↑ → Zero-shot 성능 ↑**

패턴이 나타남

3.2 Representation Learning

Zero-shot 성능과 별개로


| CLIP이 학습한 이미지 representation 자체가 얼마나 좋은가

도 평가함

이를 위해 **Linear Probe** 사용

Linear Probe

CLIP의 Image Encoder를 고정



만약 간단한 linear classifier만 붙였는데 다양한 task를 잘 해결한다면

Image Encoder가 이미 좋은 feature를 학습했다

고 볼 수 있음

논문에서는 66개 모델과 27개 데이터셋 규모의 비교를 수행함

결과적으로 모델 규모가 커질수록 CLIP representation이 크게 향상됐으며 **CLIP의 Vision Transformer가 CLIP ResNet보다 계산 효율 면에서 약 3배 좋았음**

최고 모델인 ViT-L/14@336px는 기존의 강력한 representation learning 모델과 비교해 매우 경쟁력 있는 결과를 기록함

여기서 중요한 것

CLIP의 장점은 단순히

zero-shot classification이라는 신기한 기능

만 있는 것이 아님

Image Encoder 자체도

다양한 downstream task에서 사용할 수 있는 범용 visual representation

을 학습했다는 것

그래서 이후 많은 연구에서 CLIP Image Encoder를 feature extractor로 활용하게 됨

3.3 Robustness to Natural Distribution Shift

기존 이미지 모델의 큰 문제 중 하나

| 학습 데이터와 조금만 다른 이미지가 들어오면 성능이 크게 떨어질 수 있음

예를 들어 ImageNet에서는 높은 성능인데

- ImageNet-V2
- ImageNet-A
- ImageNet-R
- ImageNet Sketch
- ObjectNet

처럼 분포가 바뀌면 성능 감소

CLIP 논문에서는 **7개의 natural distribution shift 데이터셋**을 이용해 이를 분석함

결과

Zero-shot CLIP은 일반적인 ImageNet supervised model과 비교해 distribution shift 에 더 강한 모습을 보였고, 논문 기준 **robustness gap**을 최대 약 **75%까지 감소**시킴

흥미로운 실험도 있음

CLIP feature에 ImageNet 학습 데이터를 이용해 logistic regression classifier를 학습 시키면

| ImageNet accuracy +9.2%

까지 올라감

그런데 다른 distribution shift 데이터셋의 평균 성능은 오히려 약간 감소함

즉

| 특정 데이터셋에 더 강하게 적응시키는 것이 반드시 범용적인 robustness를 높이지는
않음

이라는 결과

연구진은 zero-shot CLIP이 특정 downstream dataset에 직접 맞춰 학습되지 않았다는 점이 높은 effective robustness와 관련 있을 가능성을 제시함

단, 논문 역시 이것이 **zero-shot 자체 때문인지, 더 크고 다양한 데이터 때문인지, natural language supervision 때문인지** 완전히 분리해서 증명하지는 못했다고 설명함

4 Comparison to Human Performance

CLIP과 사람의 few-shot 학습 능력을 비교

사용 데이터셋

| Oxford-IIIT Pets

37개의 고양이·강아지 품종 분류

총 3,669개 test image를 5명의 참가자가 분류

Zero-shot

품종별 예시를 하나도 보여주지 않음

사람

| 약 53.7%

CLIP

| 약 93.5%

One-shot

각 품종의 예시 이미지 1장씩 제공

사람

| 약 75.7%

Two-shot

예시 이미지 2장씩 제공

사람

| 약 75.7%

흥미로운 것은 사람이 **0-shot** → **1-shot**에서 약 **54%** → **76%**로 급격히 향상한다는 점

반면 논문에서 사용한 CLIP few-shot 방식은 이런 인간 수준의 빠른 적응을 보여주지 못함

즉 CLIP은

| 자연어를 활용하는 zero-shot 능력은 강하지만 몇 개의 새로운 예제를 보고 빠르게 학습하는 능력은 여전히 부족

하다는 것

다만 사람과 CLIP의 학습 조건은 완전히 동일하지 않기 때문에 이 숫자를 단순한 인간 대 AI 능력 비교로 해석하면 안 됨

5 Data Overlap Analysis

CLIP에는 매우 중요한 문제가 하나 있음

| 인터넷에서 4억 개의 데이터를 수집했는데 평가 데이터가 그 안에 이미 들어 있었던 것은 아닐까

만약 ImageNet test 이미지가 pre-training 데이터에 그대로 있었다면

| 진짜 generalization이 아니라 이미 본 이미지를 기억해서 맞힌 것

일 수 있음

그래서 연구진은 **pre-training dataset과 evaluation dataset의 중복 여부**를 분석함

방법

각 평가 이미지마다 training dataset의 유사 이미지 검색

↓

유사도가 높은 데이터 확인

↓

평가 데이터를

- Overlap
- Clean

으로 분리

↓

두 집단의 accuracy 비교

결과

35개 데이터셋 중

- 9개 → 검출된 overlap 없음
- median overlap → 약 2.2%
- average overlap → 약 3.2%

대부분의 데이터셋에서 중복 때문에 전체 accuracy가 변하는 정도는 **0.1% 이하**

가장 큰 추정 성능 향상도 Birdsnap에서 약 **0.6%**

Country211은 약 21.5%의 높은 overlap이 검출됐지만 전체 accuracy 증가 추정치는 약 0.2%였음

따라서 연구진은 검출된 중복 데이터만으로 주요 성능 결과를 설명하기는 어렵다고 분석함

다만 duplicate detector가 완벽하지 않으므로 **4억 개 전체에서 모든 중복을 완벽하게 검증했다는 의미는 아님**

6 Limitations

CLIP은 범용 비전 모델의 가능성을 보여줬지만 논문에서도 상당한 한계를 직접 언급함

1. 최고 수준 task-specific 모델에는 여전히 부족

Zero-shot CLIP은 ResNet-50 기반 supervised baseline과는 경쟁 가능했지만 당시 task-specific SOTA 전체와 비교하면 여전히 차이가 있었음

논문에서 당시 scaling 추세를 단순 외삽했을 때 zero-shot CLIP이 전체적인 SOTA 수준에 도달하려면 약 **1000배의 추가 compute가 필요할 수 있다고 추정**

→ 단순히 모델만 계속 키우는 방식에는 한계

2. 복잡하거나 세밀한 task에 약함

- 자동차 세부 모델 구별
- 꽃 품종 구별
- 항공기 종류 구별
- 객체 개수 세기
- 물체 사이 거리 판단

등에서는 성능이 좋지 않음

즉 CLIP이 잘하는 것은 주로

언어로 표현되는 의미적 개념과 이미지의 연결

이고 정확한 수량이나 공간적 관계까지 완벽하게 이해하는 것은 아님

3. Truly Out-of-Distribution에 약함

CLIP은 다양한 인터넷 이미지를 학습했기 때문에 웬만한 자연 이미지에서는 강함

하지만 학습 데이터에 거의 존재하지 않는 형태는 여전히 어려움

대표 사례

| MNIST

CLIP은 디지털로 렌더링된 글자에는 강했지만 손글씨 숫자인 MNIST에서는 zero-shot accuracy가 약 88%였고, raw pixel에 logistic regression을 적용한 매우 단순한 baseline보다도 낮았음

즉

| CLIP이 OOD 문제 자체를 해결했다기보다는 엄청나게 넓은 데이터로 가능한 많은 상황을 in-distribution으로 만들어버린 것에 가까움

이라는 한계가 있음

4. 생성 모델은 아님

CLIP은

| 후보 중 어떤 텍스트가 이미지와 가장 맞는가

를 고르는 모델

따라서 이미지 captioning처럼 자유롭게 새로운 문장을 생성하지 못함

예를 들어 후보가

```
cat
dog
car
```

세 개뿐이면 반드시 그 안에서 선택해야 함

실제 정답이

| rabbit

이어도 rabbit을 새롭게 생성하는 기능은 없음

5. 엄청난 데이터 요구

4억 개 이미지-텍스트 pair를 32 epochs 학습

즉 학습 과정에서 총 약 **128억 개의 이미지 sample**을 보게 됨

논문에서는 이미지를 초당 하나씩 본다면 약 405년이 걸리는 양이라고 표현함

→ CLIP은 데이터 효율 문제를 해결했다기보다 **엄청난 데이터 규모로 보완한 측면**이 있음

6. 진정한 Zero-shot 평가의 한계

모델 개발 과정에서 연구진은 여러 validation dataset의 결과를 반복적으로 확인함
따라서

| 모델 parameter를 해당 데이터로 직접 학습하지 않았다는 의미에서는 zero-shot
이지만

| 개발자가 해당 데이터셋을 전혀 보지 않은 완전히 새로운 task

라는 의미의 엄격한 zero-shot과는 차이가 있음

7. Few-shot 학습이 비효율적

CLIP은 zero-shot은 강하지만 몇 장의 실제 예제를 효과적으로 활용하도록 직접 학습된 모델은 아님

그래서

| 강력한 Zero-shot + 인간처럼 효율적인 Few-shot

을 동시에 구현하는 것은 이후 연구 과제로 남음

7 Broader Impacts

CLIP의 장점인

| 자연어만 바꿔서 원하는 classifier를 즉시 만들 수 있음

이라는 특성은 동시에 위험 요소가 될 수 있음

예를 들어 개발자가

```
a doctor  
a criminal  
a suspicious person
```

같은 클래스를 직접 만들어 사람 이미지를 분류하는 것도 기술적으로 가능

즉 특정 데이터셋을 만들고 다시 학습할 필요 없이 **임의의 분류 기준을 쉽게 만들 수 있다는 것**

따라서 CLIP 같은 범용 모델은 단순히 평균 accuracy만 확인해서는 안 되고 **어떤 목적으로 어떤 class를 정의해 사용하는지까지 함께 평가해야 함**

7.1 Bias

인터넷 데이터에는 사회적 편향이 존재

CLIP은 이런 데이터를 그대로 대규모로 학습하기 때문에 편향도 학습할 수 있음

논문에서는 FairFace 등을 이용해 exploratory bias analysis를 수행함

특히 중요한 점은 **Class Design 자체가 bias에 영향을 줄 수 있다는 것**

예를 들어 동일한 이미지라도 후보 클래스에 무엇을 포함시키는지에 따라 결과가 크게 달라질 수 있음

```
man
woman
child
criminal
animal
...
```

어떤 label을 후보에 넣느냐가 모델의 출력과 사회적 영향을 바꿀 수 있다는 것

실험에서는 특정 demographic group의 이미지가 부정적이거나 비인간적인 category로 잘못 분류되는 비율에서 차이가 관찰됐으며, 연구진은 이를 실제 배포 환경에서의 공정성과 동일시해서는 안 되고 **초기 bias probe로 봐야 한다고 명확히 설명함**

핵심

CLIP의 bias는 단순히

┃ 모델 내부에 편향이 존재한다

만의 문제가 아님

다음이 모두 결과에 영향을 미침

- Pre-training Data
- Model Architecture
- Prompt

- Class 구성
- Decision threshold
- 실제 사용 환경

즉 CLIP처럼 자유롭게 classifier를 만드는 모델에서는 **모델뿐 아니라 사람이 어떻게 문제를 정의하는지도 중요한 위험 요소**

7.2 Surveillance

논문에서는 surveillance 관련 활용 가능성도 분석함

CLIP이 가진

- 객체 인식
- 행동 인식
- OCR
- 장소 인식
- 사람 관련 분류

기능은 감시 시스템에도 활용될 수 있기 때문

CCTV 이미지 대상으로 실험했을 때 coarse classification에서는 일정한 성능을 보였지만, 서로 매우 비슷한 선택지를 추가한 stress test에서는 정확도가 크게 떨어지는 현상도 확인함

논문에서 보고된 한 CCTV 실험은 기본 설정에서 top-1 accuracy 약 ****91.8%****였지만 비슷한 오답 선택지를 추가하자 약 ****51.1%****까지 감소함

즉 단순한 benchmark 결과만 보고

실제 감시 환경에서도 안정적으로 사용할 수 있다

고 해석하기 어렵다는 것

또한 CLIP은 새로운 classifier 제작에 별도의 training dataset이 필요하지 않기 때문에 기존에는 데이터 부족으로 만들기 어려웠던 **매우 세부적인 surveillance application을 쉽게 만들 수 있다는 점도** 위험 요소로 지적함

7.3 Future Work

연구진은 앞으로 범용 비전 모델을 평가할 때 단순 accuracy를 넘어

- 어떤 새로운 능력이 나타나는지

- 어떤 task에서 실패하는지
- 어떤 편향이 존재하는지
- 민감한 영역에서 어떻게 사용될 수 있는지
- 어떤 application에서는 AI 자체의 사용이 부적절한지

등을 지속적으로 평가해야 한다고 주장함

8 Related Work

CLIP은 완전히 새로운 아이디어 하나로 갑자기 등장한 모델은 아님

여러 연구 흐름을 결합한 결과에 가까움

Natural Language Supervision

이미지와 자연어 설명을 연결하여 visual representation을 학습하려는 연구는 이전부터 존재

Image-Text Retrieval

이미지와 텍스트를 같은 embedding space로 만들어 서로 검색하는 연구 역시 오래전부터 존재

CLIP의 contrastive objective도 본질적으로

올바른 image-text pair를 가깝게 만드는 image-text retrieval objective

라고 볼 수 있음

Contrastive Learning

InfoNCE 등 contrastive learning 연구에서 사용한 아이디어를 image-text pair에 대규모로 적용

Zero-shot Learning

언어 정보를 이용해서 학습하지 않은 category를 예측하려는 연구 역시 기존에 존재

CLIP의 차별점

CLIP의 핵심 새로움은 각각의 구성요소를 처음 만든 것이 아니라

단순한 contrastive image-text learning을 4억 개 규모까지 확장했을 때 범용적인 zero-shot visual model이 나타난다는 것을 보여준 것

에 가까움

또한 당시 BERT 계열 Vision-Language 모델처럼 이미지와 텍스트를 복잡한 joint attention network에 함께 넣는 대신

| Image Encoder와 Text Encoder를 독립적으로 사용하고 마지막에 embedding similarity만 계산

하는 단순한 구조를 선택함

이 덕분에 이미지와 텍스트 embedding을 미리 계산해 둘 수 있어 retrieval과 zero-shot classification에서 효율적으로 활용 가능함